Instrucciones Paso a Paso para los Estudiantes

Paso 1: Selección del Contexto u Organización

Sector Eléctrico Colombiano - Mercado de Usuarios No Regulados (Grandes consumidores industriales).

Paso 2: Lluvia de Ideas y Filtrado (The ML Fit)

Descripción IDEA1: Ineficiencia financiera al decidir cuánta energía comprar en la bolsa (volátil) versus cuánta asegurar mediante contratos bilaterales (precio fijo), debido a la incapacidad de anticipar el precio de la bolsa y la demanda propia.

- **¿Reglas simples o patrones complejos?:** Requiere aprender patrones complejos. El precio de la bolsa y la demanda tienen un comportamiento estocástico, no lineal, afectado por el clima (fenómeno de El Niño/La Niña), niveles de embalses, días festivos y ciclos de producción.
- **¿Volumen de datos suficiente?:** Sí. El portal SIMEM, administrado por XM, provee series de tiempo con resolución horaria sobre precios, demanda y variables hidrológicas, permitiendo un entrenamiento profundo con datos desde 2022 en adelante.
- **Costo de equivocarse:**
    - ***Falso Positivo (predecir bolsa barata cuando será muy cara):*** La empresa se expone al mercado *spot* durante un pico tarifario, asumiendo sobrecostos operacionales catastróficos.
    - ***Falso Negativo (predecir bolsa cara cuando será barata):*** La empresa se sobrecontrata a precio fijo, perdiendo el costo de oportunidad de comprar energía económica y reduciendo su margen de ganancia.

Descripción IDEA2: Predicción a corto plazo del consumo masivo de los hogares para que empresas como EPM sepan cuánta energía comprar con anticipación.

- **¿Reglas simples o patrones complejos?:** Requiere patrones complejos, ya que el consumo residencial depende de interacciones no lineales entre el clima, el estrato socioeconómico y el calendario.
- **¿Volumen de datos suficiente?: (Filtro no superado)**. Aunque la demanda agregada nacional es pública, los datos internos de los contratos y las curvas de carga específicas de los clientes de una comercializadora son estrictamente confidenciales y están protegidos por secreto corporativo, lo que hace imposible recolectar el dataset completo para este proyecto.
- **Costo de equivocarse:** Muy alto. Un falso positivo (predecir alta demanda erróneamente) obliga a la empresa a sobrecontratarse, perdiendo millones en energía que los hogares no van a consumir.

Descripción IDEA3: Identificación de medidores alterados o conexiones ilegales en la red de distribución mediante el análisis de anomalías en el consumo de los usuarios.

- **¿Reglas simples o patrones complejos?:** Requiere Machine Learning (Clasificación/Detección de Anomalías) porque los fraudes modernos son sutiles y evaden las reglas lógicas simples simulando consumos parciales.
- **¿Volumen de datos suficiente?: (Filtro no superado)**. No hay bases de datos públicas sobre fraudes eléctricos. Los registros pertenecen a los sistemas de facturación de los operadores de red, contienen información personal (protegida por la Ley 1581 de protección de datos) y carecen de etiquetas confiables, ya que confirmar un fraude requiere costosas inspecciones físicas en terreno.
- **Costo de equivocarse: (Riesgo inaceptable)**. El costo de un falso positivo es catastrófico. Acusar a un cliente honesto de un delito (robo de energía) basándose en una predicción algorítmica desencadena demandas legales, multas de la Superintendencia y un daño reputacional severo para la compañía.

IDEA 1 ELEGIDA PARA DESARROLLAR EL PROYECTO

Paso 3: Definición del Problema bajo el Enfoque de Machine Learning

Componente	Descripción / Pregunta a responder
Objetivo de Negocio	Minimizar el costo financiero de adquisición de energía eléctrica para un gran consumidor no regulado, optimizando la estrategia de compra en bolsa frente a contratos bilaterales.
Métrica de Éxito Comercial	Reducción porcentual del costo total de compra de energía en comparación con las estrategias de compra deterministas o históricas de una empresa.
Tarea de ML	Regresión (Aprendizaje supervisado para la predicción de series de tiempo multivariadas continuas).
La Variable Objetivo (\(Y\))	Vectores horarios continuos de Demanda de Energía Eléctrica No Regulada (kWh) y Precio de Bolsa Nacional (COP/kWh).
Características Sugeridas (\(X\))	● Rezagos dinámicos temporales (t=1, t=24) de la demanda y del precio ● Nivel agregado de embalses del sistema (%) ● Aportes hídricos de los ríos del país. ● Precio histórico de los contratos bilaterales despachados. ● Componentes de calendario (hora, día de la semana, mes, festivos)

Paso 4: Auditoría de Datos y Factibilidad

Analicen la situación de los datos requeridos:

- **Disponibilidad:** Los datos ya existen y son de acceso público. Se extraerán desde el portal de información SIMEM, administrado por XM. Comprenderán series de tiempo con registros horarios continuos desde el año 2022 en adelante.

- **Privacidad y Ética:** Los datos corresponden a variables macroeconómicas, climáticas y de despacho energético industrial. No contienen información personal, por lo que no entran en conflicto con regulaciones de privacidad de datos personales. Para mitigar sesgos por rupturas estructurales del sistema (cambios de régimen tarifario o fenómenos climáticos extremos), se aplicarán métodos estadísticos robustos para etiquetar eventos atípicos sin alterar la distribución global del entrenamiento.

Paso 5: Preparación del Entregable

Integrantes	
Esteban Daza Palomino	**Julián Gallego Villa**
Isabel Suárez Londoño	**Sara Jurado Giraldo**
Kevin González Duarte	**Stiven Saldarriaga Mayorga**
Introducción y contexto organizacional	
Nombre de la organización o sector:	Sector Eléctrico Colombiano - Mercado de Usuarios No Regulados (Grandes consumidores industriales de Energía Eléctrica).
Diagnóstico del problema y justificación de ML	
Descripción del problema:	Para un gran consumidor industrial, el mercado eléctrico plantea un doble desafío de alta incertidumbre; por un lado, su propia demanda de energía es variable debido a los ciclos de producción y por otro, el precio de la bolsa nacional sufre fluctuaciones drásticas dictadas por el clima y las restricciones del sistema. Intentar anticipar este consumo y definir una estrategia de compra *(Bolsa vs. Contratos Bilaterales*) utilizando reglas tradicionales o promedios estáticos resulta altamente ineficiente. Por ello, es indispensable implementar una solución integrada mediante modelos profundos de Machine Learning que capturen las dependencias no lineales para predecir con exactitud tanto la demanda como los precios,

	acoplados a un motor de optimización matemática que dicte la decisión financiera más rentable hora a hora.
Impacto actual:	Hoy en día, la compra ineficiente de energía representa una fuga de capital importante para la industria. Al tomar decisiones sin respaldo estadístico, las empresas terminan sacrificando sus márgenes de ganancia por caer en dos extremos; o pagan la energía más cara de lo necesario al sobrecontratarse por miedo al riesgo, o quedan vulnerables a la extrema volatilidad de la bolsa durante las épocas de sequía.
Formulación técnica del problema de ML	
Paradigma del ML (supervisado, no supervisado, aprendizaje por refuerzo)	Aprendizaje supervisado.
Tarea específica de ML (Clasificación, regresión)	Regresión multivariada para pronóstico de series de tiempo. Se implementarán y compararán arquitecturas profundas de ML como (LSTM, RNN, GRU y TCN).
Variable objetivo	$Y_t = \left[Demanda_t,\ PrecioBolsa_t\right]^T$
Formulación del problema de optimización	
Función objetivo	Minimizar el costo económico de adquisición de energía, lo cual corresponde a un problema de optimización con restricciones de la forma: $\min_{x \in \varphi} f(x)$ $\min \sum_t \left(x_{1,t} \cdot P_t^{\text{Bolsa}} + x_{2,t} \cdot P_t^{\text{Contrato}}\right)$

Variables de diseño	Representan las variables de valores desconocidos que caracterizan la decisión del sistema. $x_{1,t}$: Cantidad de energía a comprar en la bolsa en la hora t. $x_{2,t}$: Cantidad de energía a comprar en contratos bilaterales en la hora t. Restricción Principal (φ): $x_{1,t} + x_{2,t} = D_t$, donde D_t es la demanda de energía eléctrica de usuarios no regulados predicha. $X = \left[x_{1,1}, x_{2,1}, x_{1,2}, x_{2,2}, \ldots, x_{1,T}, x_{1,T}\right]^T$
Auditoria de datos	
Fuentes existentes:	Series de tiempo multivariadas extraídas del Portal de Información SIMEM (XM S.A. E.S.P.)
Brechas de datos:	El historial del mercado de energía ecléctica de usuarios no regulados presenta cambios abruptos y saltos extremos tanto en el comportamiento de la demanda como en los precios. Para manejar esta volatilidad, es indispensable aplicar un preprocesamiento que descomponga las series de tiempo y aísle sus patrones estables (residuos estacionarios). Este paso de limpieza es fundamental para garantizar que las redes neuronales recurrentes y redes neuronales con otras arquitecturas se calibren de manera correcta y no se confundan con los choques del mercado.
Consideraciones éticas, de privacidad y riesgos de adopción	
Privacidad y regulación de datos (¿Los datos involucran información personal sensible o protegida por normativas de	Los datos utilizados son de dominio público y comercial, limitándose a variables operativas del mercado eléctrico (demanda industrial agregada, precios de bolsa e indicadores

privacidad (Ej. RGPD, leyes locales)? ¿Cómo se garantizará el anonimato?)	hídricos). Al no contener información personal ni variables sensibles, el proyecto está exento de los alcances restrictivos del RGPD y de las leyes locales de protección de datos (Ley 1581). El anonimato está garantizado de manera inherente, dado que las mediciones de demanda se manejan a nivel de agregación sectorial, imposibilitando cualquier trazabilidad hacia personas naturales.
Mitigación de sesgos inherentes (¿Qué sesgos históricos podrían estar presentes en los datos de entrenamiento y cómo podrían afectar las decisiones del modelo hacia ciertos grupos?)	Uno de los principales riesgos es que el modelo desarrolle sesgos al aprender de memoria comportamientos atípicos del pasado, como las sequías prolongadas, perpetuando estos patrones en lugar de aprender a generalizar. Para evitar esto y garantizar un modelo verdaderamente robusto, implementaremos una partición cronológica estricta que bloquee posibles problemas de *data leakage*. Además, blindaremos el entrenamiento ajustando los hiperparámetros del algoritmo mediante técnicas metaheurísticas