Pronóstico horario de la demanda no regulada y del precio de bolsa en Colombia con redes neuronales

Esteban Daza Palomino · Sara Jurado Giraldo · Isabel Suárez Londoño · Kevin González Duarte · Stiven Saldarriaga Mayorga

Universidad Nacional de Colombia, Sede Medellín · Optimización e Inteligencia Artificial · 2026-II

Datos: XM S.A. E.S.P. 2022–2026

Modelos: PyTorch

Código y datos en GitHub

Descripción del problema

Los usuarios no regulados (industrias y grandes comercios) liquidan en bolsa la energía que no tienen contratada, y su precio puede multiplicarse en pocas semanas: pasó de **216 COP/kWh** en 2022 a **676** en 2024 por El Niño. Planear compras y consumo exige anticipar, a las 00:00, **la demanda y el precio de las 24 horas del día siguiente.**

- **Tarea:** regresión multivariada de series de tiempo, supervisada. Entrada: 168 h de historia y el calendario de mañana. Salida: 24 h × 2 series.
- **Optimización:** entrenar una red es minimizar el error cuadrático medio sobre sus pesos; el resultado depende del optimizador, la tasa de aprendizaje y la regularización.
- **Métodos:** 5 redes (RNN, TCN, GRU, LSTM, Transformer) y 8 optimizadores sobre las dos mejores.

$$\min_{\mathbf{w}} \frac{1}{N}\sum_{i=1}^{N}\frac{1}{48}\left\|\mathbf{Y}_i-\widehat{\mathbf{Y}}_i\right\|_F^2$$

Metodología

Tres fases con las mismas reglas para todas las redes: mismos datos, misma pérdida y parada temprana.

Fase 1 · Datos
API de XM (40.896 h) → limpieza, 16 variables y escalado → ventanas de 168 h a 24 h

↓

Fase 2 · Modelamiento
5 redes con Adam, $\texttt{lr}=10^{-3}$

↓

Selección en validación
Criterio fijado antes de ver resultados: pasan GRU y TCN

↓

Fase 3 · Optimización
4 etapas por red: (1) optimizador × 8, (2) regularización × 8, (3) arquitectura × 5, (4) 3 semillas

↓

Modelo final: GRU optimizada
Evaluada en validación y prueba

Base de datos

- **Fuente:** API pública de XM (`pydataxm`), ene 2022 a ago 2026: **40.896 horas**, sin huecos ni nulos.
- **Atributos:** 2 objetivos horarios (demanda no regulada y precio de bolsa) y 3 exógenas (precio de contratos, aportes hídricos, volumen útil).
- **Preprocesamiento:** 16 variables de entrada con calendario cíclico y festivos; hidrología rezagada 1 día (sin fuga de información); `log1p` y z-score en precio y aportes.

Partición	Periodo	Ventanas	
Entrenamiento	ene 2022 – jun 2025	30.265	1 por hora
Validación	jul – dic 2025	184	1 por día
Prueba	ene – ago 2026	243	1 por día

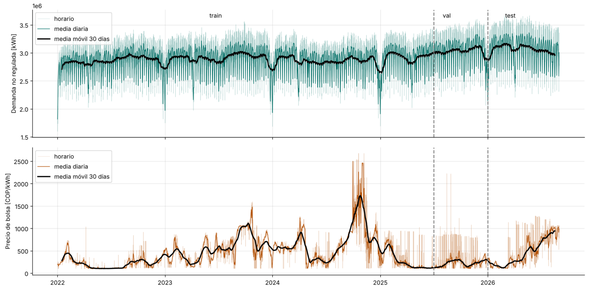
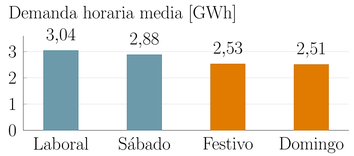


Figura 1. Demanda no regulada y precio de bolsa, 2022–2026. Las líneas punteadas separan entrenamiento, validación y prueba.

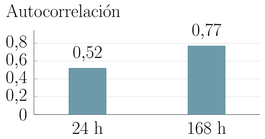
Hallazgos del análisis

Un festivo es un domingo.

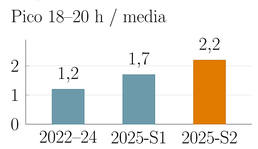
Domingos y festivos consumen un 17 % menos que un día laboral, y 76 de los 84 festivos del periodo cayeron entre semana: el calendario necesita un indicador de festivo.



La demanda es semanal.



El precio cambió de forma.



Por eso la ventana es de 168 h y la validación (2025-S2) es el periodo más difícil.

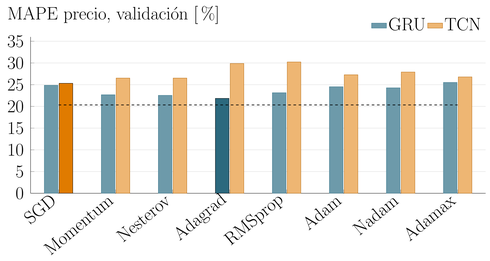
Modelamiento: 5 redes neuronales

Todas superan al naive semanal en demanda. En precio, pasan a la fase 3 las dos más cercanas al naive diario (en naranja):

RNN **LSTM** **Transformer** **TCN** **GRU**

Optimización: 8 optimizadores

El mejor optimizador cambia según la red.



Barras oscuras: el mejor de cada red. Punteada: mejor naive del precio (20,34 %).

Lectura clave. Cambiar el optimizador movió el MAPE de precio hasta 5 puntos; Adam, el de la fase 2, no ganó en ninguna.

Resultados

Tras optimizar, la **GRU** queda en **2,04 %** de MAPE de demanda y **20,90 %** de precio en validación.

Modelo (validación)	MAPE dem. [%]	MAPE precio [%]	R^2 precio
Naive semanal ($m=168$)	3,83	37,45	0,22
Naive diario ($m=24$)	6,72	**20,34**	0,48
RNN	2,24	37,21	0,32
LSTM	3,10	32,38	0,33
Transformer	2,80	31,25	0,43
TCN, fase 2	2,49	27,43	0,56
GRU, fase 2	2,41	23,55	0,58
TCN optimizada	3,62	20,95	0,54
GRU optimizada	**2,04**	20,90	**0,61**

Validación: jul–dic 2025. Fase 3: media de 3 semillas. Naive: repite el valor de hace 24 h o 168 h.

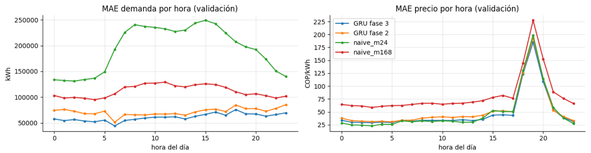


Figura 2. MAE por hora en validación (m24 y m168: naive diario y semanal). La GRU optimizada falla menos en demanda a toda hora y en el pico de precio.

Modelo ganador: GRU optimizada

GRU con corrección del naive y Adagrad ($\texttt{lr}=10^{-2}$): 2 capas de 48 unidades y atención sobre las 168 h. Pronostica las 24 h en una sola pasada.

2,04 %
MAPE demanda, validación
(naive semanal: 3,83 %)

2,30 %
MAPE demanda, prueba 2026
(naive semanal: 4,06 %)

20,90 %
MAPE precio, validación
(naive diario: 20,34 %)

34.178
parámetros:
la red más pequeña de las cinco

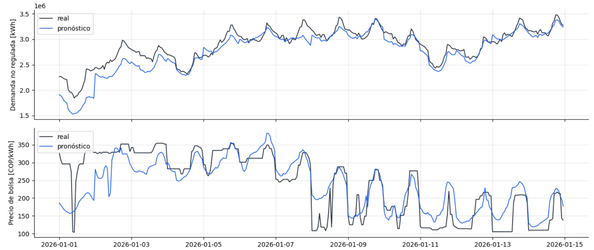


Figura 3. Pronóstico (azul) frente a lo real (negro), primeros 14 días de prueba (enero de 2026). Del 1 al 3 de enero subestimó la demanda.

Conclusiones

1. **Demanda:** la GRU optimizada logra 2,04 % en validación y 2,30 % en prueba, cerca de la mitad del error del naive semanal.
2. **Precio:** el naive diario es la referencia más difícil. La GRU lo iguala en MAPE y lo supera en RMSE (96,7 frente a 111,8) y R^2 (0,61 frente a 0,48): falla menos en los picos.
3. **La optimización importa y depende de la red:** Adagrad en la GRU, SGD en la TCN; Adam no ganó en ninguna.
4. **Siguiente paso:** el precio necesita información que hoy falta (disponibilidad térmica, ofertas) o una pérdida que pese más los picos.

Referencias

1. XM S.A. E.S.P. API de datos y `pydataxm`. github.com/EquipoAnaliticaXM/API_XM
2. Hyndman, R. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. OTexts.
3. Hochreiter, S. y Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8).
4. Cho, K. et al. (2014). Learning Phrase Representations using RNN Encoder–Decoder. arXiv:1406.1078
5. Bai, S. et al. (2018). Generic Convolutional and Recurrent Networks. arXiv:1803.01271
6. Vaswani, A. et al. (2017). Attention Is All You Need. arXiv:1706.03762
7. Duchi, J. et al. (2011). Adaptive Subgradient Methods. *JMLR*, 12.
8. Kingma, D. y Ba, J. (2015). Adam: A Method for Stochastic Optimization. arXiv:1412.6980